

Separación exploratoria de tipos tumorales usando perfiles RNA-Seq, PCA y K-Means

801

muestras tumorales

20,531

genes originales

5,000

genes retenidos

k = 5

clusters elegidos

Pregunta del trabajo: ¿una matriz de expresión génica de alta dimensionalidad conserva estructura suficiente para recuperar tipos tumorales mediante un flujo no supervisado?

Contexto biológico

La expresión génica mide qué tan activos están los genes en una muestra. En cáncer, distintos tipos tumorales pueden tener genes más o menos activos.

RNA-Seq permite observar esos perfiles a escala transcriptómica. En este trabajo se analiza una matriz de expresión ya procesada de TCGA/PANCAN.

La dificultad computacional es la dimensión: cada muestra se describe por miles de genes, lo que exige reducción de dimensión antes de visualizar.

Matriz conceptual

muestra	gen 1	gen 2	...	gen 20531
BRCA_001			...	
KIRC_014			...	
LUAD_071			...	
PRAD_022			...	
COAD_008			...	

Cada fila es una muestra tumoral; cada columna es un gen; cada celda es un nivel de expresión.

Dataset usado

Gene Expression Cancer RNA-Seq, UCI Machine Learning Repository. Proviene de TCGA/PANCAN RNA-Seq y ya viene como matriz procesada.

Forma del dataset

X: 801 muestras tumorales x 20,531 genes. Filas = muestras; columnas = genes; celdas = niveles numéricos de expresión.

y: etiqueta real del tipo tumoral. Incluye BRCA, COAD, KIRC, LUAD y PRAD.

- BRCA: cáncer de mama.
- COAD: adenocarcinoma de colon.
- KIRC: carcinoma renal de células claras.
- LUAD: adenocarcinoma de pulmón.
- PRAD: adenocarcinoma de próstata.


Las etiquetas no se usan para agrupar; se usan después para evaluar los clusters.

0

celdas vacías

5

tipos tumorales



Distribución real de clases

Objetivo: evaluar si perfiles de expresión génica RNA-Seq se agrupan de acuerdo con su tipo tumoral cuando se reduce la dimensión con PCA y se aplica K-Means sin usar etiquetas.



Criterio esperado: si cada tipo tumoral tiene genes activos de forma distinta, las muestras del mismo tipo deberían quedar más cerca entre sí que de otros tumores en PCA y K-Means.

Qué hace el código

1. Lee la matriz de expresión y la columna de tipo tumoral real.
2. Revisa que X e y tengan las mismas muestras y que no existan celdas vacías o columnas no numéricas.
3. Conserva los 5,000 genes con mayor varianza y estandariza sus valores.
4. Calcula PCA para representar cada muestra con pocas coordenadas.
5. Ejecuta K-Means con varios valores de k y compara los clusters contra las etiquetas reales.

Recorrido ejecutable

```
run_pipeline(...)
load_expression_data(...)
validate_expression_dataset(...)
select_high_variance_genes(...)
standardize_features(...)
run_pca(...)
evaluate_kmeans(...)
build_contingency(...)
evaluate_cluster_label_alignment(...)
save_result_tables(...)
```

El notebook llama run_pipeline. Si se vuelve a ejecutar, se regeneran las mismas tablas y gráficas desde los datos.

Entrada esperada

data.csv contiene la matriz de expresión. labels.csv contiene el tipo tumoral de cada muestra.

El código elimina la columna de identificador cuando existe y alinea las etiquetas con las filas de expresión.

La validación detiene el análisis si hay faltantes, columnas no numéricas, índices duplicados o desajuste entre X e y.

Validaciones implementadas

- X.empty -> no hay matriz que analizar
- len(X) != len(y) -> faltan etiquetas
- duplicados -> muestras repetidas
- y con vacíos -> muestra sin tipo tumoral
- X con vacíos -> expresión incompleta
- no numéricas -> PCA/K-Means no aplican
- < 2 clases -> no hay comparación real

801
muestras

20,531
genes

0
celdas vacías

Qué mide

La varianza mide cuánto cambian los valores de un gen entre las muestras.

Si un gen tiene valores muy parecidos en casi todos los tumores, no ayuda mucho a distinguir muestras.

Si un gen cambia bastante entre tumores, puede aportar señal para PCA y K-Means.

Por eso el flujo conserva los 5,000 genes con mayor varianza antes de reducir dimensión.

Ejemplo simplificado

gen	S1	S2	S3	S4	lectura
gen_A	10	11	10	11	baja varianza
gen_B	2	40	5	35	alta varianza

La selección por varianza no dice que un gen sea clínicamente importante; sólo prioriza genes que cambian más en esta matriz.

Qué significa

Estandarizar es poner todos los genes en una escala comparable.

Para cada gen se resta su media y se divide entre su desviación estándar.

Después de eso, cada gen queda centrado alrededor de 0 y sus cambios se miden en unidades comparables.

Esto importa porque PCA usa varianza y K-Means usa distancias.

Por qué se aplica

Sin estandarizar, un gen con números grandes puede dominar el análisis aunque no sea más importante.

Ejemplo: si un gen va de 0 a 10,000 y otro de 0 a 10, las distancias quedan dominadas por el primero.

Con estandarización, ambos genes pueden contribuir según su patrón de cambio, no sólo por la magnitud de sus valores.

En el código se hace con `StandardScaler` sobre la matriz ya filtrada por varianza.

1. Revisión

801 muestras, 20,531 genes, 0 valores faltantes.

2. Varianza

Retuve 5,000 genes que más cambian entre muestras.

3. Escala

Estandaricé cada gen para comparar columnas en una escala común.

Por qué seleccionar por varianza

Si un gen casi no cambia entre muestras, aporta poco para separar perfiles tumorales.

Seleccionar genes variables reduce dimensión antes de PCA.

Este criterio selecciona variación estadística, no relevancia clínica.

Por qué estandarizar

PCA depende de varianza y K-Means depende de distancias.

Si una columna tiene escala mayor, puede dominar aunque no sea más informativa.

La estandarización pone los genes en una escala comparable.

Selección por varianza

```
variances = X.var(axis=0, ddof=0)
variances = variances.sort_values(
    ascending=False
)
selected = variances.head(5000).index
X_selected = X.loc[:, selected]
```

La selección se hace antes de estandarizar para conservar genes con mayor cambio observado entre muestras.

Estandarización

```
scaler = StandardScaler()
scaled_values = scaler.fit_transform(
    X_selected
)
X_scaled = DataFrame(
    scaled_values, index, columns
)
```

Cada gen queda con media cercana a 0 y desviación estándar cercana a 1.

Qué hace PCA

PCA toma una matriz con miles de genes y crea nuevos ejes numéricos llamados componentes principales.

PC1 resume la mayor diferencia global entre muestras; PC2 resume otra diferencia importante, independiente de PC1.

No usa las etiquetas tumorales para construir esos ejes: sólo usa los valores numéricos de expresión.

Así se puede dibujar cada muestra como un punto en PC1 vs PC2.

Para qué sirve aquí

El dataset tiene 20,531 genes por muestra. Eso no se puede visualizar directamente en una gráfica de dos ejes.

PCA reduce esa información a coordenadas comparables sin perder toda la estructura.

Después se revisa si las muestras del mismo tipo tumoral tienden a quedar cerca en la proyección.

También se usan las coordenadas PCA como entrada reducida para K-Means.

Objeto que entra


PCA recibe `X_scaled`, la matriz ya filtrada y estandarizada.

El código calcula hasta 10 componentes, limitado por número de muestras y genes.


La salida principal son los scores: nuevas coordenadas PC1, PC2, ..., PC10 para cada muestra.

Implementación

```
model = PCA(n_components=max_components)
scores_array = model.fit_transform(
    X_scaled
)
scores = DataFrame(scores_array,
    columns=[PC1, ..., PC10]
)
explained = model.explained_variance_ratio_
cumulative = explained.cumsum()
```



Cada barra indica cuánto aporta cada componente



La curva suma lo capturado por varios componentes

15.46%
PC1


11.34%
PC2

26.81%
PC1 + PC2

56.02%
10 componentes

Lectura: PC1 y PC2 son los dos ejes principales usados para dibujar la proyección. Juntos capturan 26.81% de la variación total.

Interpretación: la separación visible en PC1-PC2 usa sólo una parte de la información; con 10 componentes se captura 56.02%, por eso K-Means usa más coordenadas que la gráfica 2D.



PC1 contra PC2 coloreado por etiqueta real

Lectura principal

BRCA, KIRC y PRAD ocupan regiones diferenciadas del plano.

LUAD y COAD quedan más cercanos entre sí, lo que anticipa mayor mezcla en clustering.

PC1 y PC2 juntan 26.81% de las diferencias numéricas entre muestras. La gráfica ayuda a explorar, pero no muestra toda la tabla original.

Qué hace

K-Means agrupa muestras según cercanía numérica.

Aquí no ve nombres como BRCA o LUAD; sólo recibe coordenadas PCA de cada muestra.

k indica cuántos grupos se le pide formar. En el resultado final se usó $k = 5$.

La salida es un número de cluster para cada muestra: 0, 1, 2, 3 o 4.

Cómo trabaja

1. Coloca centros iniciales llamados centroides.
2. Asigna cada muestra al centro más cercano.
3. Recalcula los centros con las muestras asignadas.
4. Repite hasta que los grupos cambien poco.

Después se compara cada cluster contra las etiquetas reales para ver si coincide con tipos tumorales.

Evaluación de varios k

```
for k in range(2, 11):
    model = KMeans(
        n_clusters=k,
        random_state=42,
        n_init=20
    )
    labels = model.fit_predict(matrix)
    db = davies_bouldin_score(matrix, labels)
    sil = silhouette_score(matrix, labels)
```

Decisión implementada

El código guarda una fila por cada k evaluado: k, Davies-Bouldin y Silhouette.

El k final se toma del menor Davies-Bouldin en el rango evaluado.

Con ese k se conserva el modelo ajustado y la etiqueta de cluster de cada muestra.



Entrada


K-Means recibió las coordenadas PCA de cada muestra.

Proceso

Ubica centroides, asigna puntos cercanos y actualiza centros hasta estabilizar.

Salida

Devuelve números de cluster: 0, 1, 2, 3 y 4. Esos números no tienen significado biológico propio.



Criterio de agrupamiento

Cada punto es una muestra. Si dos puntos están cerca, sus perfiles de expresión son parecidos en la representación PCA.

El algoritmo recibe coordenadas numéricas y asigna cada muestra al centroide más cercano.

La relación con el tipo tumoral se evalúa al final.

Davies-Bouldin

Compara compactación interna y separación entre clusters. Valores menores indican grupos más definidos.

Silhouette

Compara la cercanía de una muestra a su cluster contra la cercanía al cluster vecino. Valores mayores son mejores.

Lectura conjunta

Ambas métricas evalúan geometría del agrupamiento; no usan el tipo tumoral real.

Qué mide Davies-Bouldin

Un cluster compacto tiene puntos cercanos a su centroide.

Dos clusters separados tienen centroides lejanos entre sí.


El índice penaliza clusters dispersos o demasiado cercanos.

Qué mide Silhouette

Cerca de 1: la muestra encaja claramente en su cluster.

Cerca de 0: la muestra queda en una frontera entre clusters.

Menor que 0: la muestra probablemente quedó en otro grupo.



Resultado en el rango evaluado

Se probaron valores de k entre 2 y 10.

k=5 produjo el menor Davies-Bouldin: 0.931.

Silhouette fue 0.456 en k=5 y 0.465 en su máximo del rango.

La decisión conserva k=5 porque combina calidad interna y correspondencia posterior con tipos tumorales.

Davies-Bouldin y Silhouette por k

0.931

Davies-Bouldin en k=5

0.456

Silhouette en k=5

0.465

mejor Silhouette

El resultado muestra una estructura interna moderada y una partición final compatible con cinco grupos.

Pureza

Mide si cada cluster está dominado por una clase real. Valores altos indican clusters con una clase predominante.

ARI

Compara la partición de K-Means contra las etiquetas reales y corrige parte del acuerdo esperado por azar.

NMI

Mide cuánta información comparten clusters y tipos tumorales. Valores altos indican alta correspondencia.

Diferencia con las métricas internas

Davies-Bouldin y Silhouette evalúan sólo la forma geométrica de los clusters.

Pureza, ARI y NMI comparan los clusters contra los tipos tumorales reales.

Por eso se calculan después de ejecutar K-Means.

Valores observados

0.991

pureza


0.983

ARI

0.972

NMI

Los tres valores son cercanos a 1, lo que indica alta correspondencia entre clusters y tipos tumorales.



Tipo tumoral real contra cluster asignado

Evaluación externa



BRCA, PRAD y KIRC se recuperan con alta claridad. La mezcla principal aparece entre COAD y LUAD.

Las etiquetas reales se incorporan en esta etapa de evaluación posterior.

El agrupamiento previo se hizo sólo con coordenadas numéricas.

1. Hay señal transcriptómica.

Los perfiles RNA-Seq contienen diferencias suficientes para separar muestras por tipo tumoral.

2. PCA mostró estructura.

La proyección PC1-PC2 separa varios tipos tumorales antes de evaluar los clusters contra etiquetas reales.

3. K-Means recuperó grupos consistentes.

Los clusters coinciden ampliamente con las clases reales: pureza 0.991, ARI 0.983 y NMI 0.972.

4. COAD y LUAD fueron los casos menos separados.

En la tabla de contingencia son los tipos tumorales con mayor cercanía entre clusters. En cambio, BRCA, PRAD y KIRC quedan asociados a grupos más definidos.

5. La reducción de dimensión permitió comparar las muestras.

El flujo transformó 20,531 genes por muestra en componentes PCA y clusters. Con eso fue posible medir qué tanto coincidían los grupos encontrados con los tipos tumorales reales.

Bibliografía abreviada

Fiorini (2016). Gene Expression Cancer RNA-Seq. UCI Machine Learning Repository. DOI: 10.24432/C5R88H.

Wang, Gerstein y Snyder (2009). RNA-Seq: a revolutionary tool for transcriptomics. Nature Reviews Genetics.

TCGA Research Network (2013). The Cancer Genome Atlas Pan-Cancer analysis project. Nature Genetics.

Jolliffe y Cadima (2016). Principal component analysis: a review and recent developments. Philosophical Transactions A.

Lloyd (1982). Least squares quantization in PCM. IEEE Transactions on Information Theory.

Davies y Bouldin (1979). A cluster separation measure. IEEE TPAMI.

Rousseeuw (1987). Silhouettes: validation of cluster analysis. Journal of Computational and Applied Mathematics.

Hubert y Arabie (1985). Comparing partitions. Journal of Classification.

Vinh, Epps y Bailey (2010). Information theoretic measures for clusterings comparison. JMLR.