

Separación exploratoria de tipos tumorales mediante perfiles de expresión génica RNA-Seq, PCA y K-Means

Juan Jose Arroyo Rivera

Proyecto final - Genómica Computacional

Resumen

Este trabajo analiza si los perfiles de expresión génica obtenidos por RNA-Seq contienen estructura suficiente para distinguir, de manera exploratoria, distintos tipos tumorales. Para ello se utiliza el conjunto *Gene Expression Cancer RNA-Seq* del UCI Machine Learning Repository, que reúne 801 muestras, 20,531 atributos de expresión génica y cinco clases tumorales: BRCA, KIRC, COAD, LUAD y PRAD (Fiorini, 2016). El análisis no busca construir una herramienta diagnóstica ni proponer un marcador clínico, sino observar si una matriz de expresión de alta dimensionalidad puede revelar agrupamientos coherentes cuando se reduce su dimensión y se aplica un método no supervisado.

La metodología parte de una matriz de expresión ya procesada, continúa con selección de genes por varianza y estandarización, aplica análisis de componentes principales y después agrupa las muestras mediante K-Means. La calidad interna de los agrupamientos se revisa con Davies-Bouldin y Silhouette; posteriormente, las etiquetas reales se usan para interpretar los clusters mediante matriz de contingencia, pureza, ARI y NMI. Con 5,000 genes retenidos por varianza, las dos primeras componentes explicaron 26.81% de la variación y las diez primeras explicaron 56.02%. El valor de k con mejor índice de Davies-Bouldin fue 5, con Silhouette de 0.4555 para esa partición. La comparación externa mostró pureza de 0.9913, ARI de 0.9829 y NMI de 0.9717, lo que indica una correspondencia fuerte entre clusters y tipos tumorales, con mayor mezcla entre COAD y LUAD.

Introducción

La expresión génica describe el grado en que los genes se encuentran activos en una muestra biológica. En el contexto del cáncer, esta información es relevante porque distintos tumores pueden activar o silenciar conjuntos de genes asociados con procesos celulares particulares. RNA-Seq permite medir la abundancia de transcritos a escala transcriptómica mediante secuenciación de alto rendimiento, lo que ha convertido a esta técnica en una herramienta central para estudiar perfiles de expresión (Wang, Gerstein y Snyder, 2009). En este proyecto no se procesan lecturas crudas de secuenciación; se trabaja con una matriz ya procesada de niveles de expresión, de modo que el problema principal es computacional y exploratorio.

Esa matriz tiene una dificultad inmediata: cada muestra está representada por miles de genes. En el dataset usado, la representación original contiene 20,531 atributos por muestra (Fiorini, 2016). Un espacio con esa cantidad de variables no puede inspeccionarse directamente en una gráfica bidimensional, y además puede contener variables redundantes o poco informativas para el patrón global. Por esa razón se requiere transformar la matriz a una representación más compacta antes de intentar visualizar relaciones entre muestras.

El análisis de componentes principales, o PCA, cumple ese papel. Antes de nombrarlo como técnica, conviene entender su función práctica: toma muchas variables numéricas y construye nuevas direcciones que resumen la variación más importante de los datos. La primera componente principal captura la mayor variación posible; la segunda captura la mayor variación restante bajo la restricción de ser perpendicular a la primera. En términos exploratorios, PCA permite conservar una parte de la estructura del conjunto mientras se proyectan las muestras a

dos o tres dimensiones interpretables (Jolliffe y Cadima, 2016).

Después de esa reducción, el segundo problema consiste en evaluar si las muestras forman grupos naturales sin usar sus etiquetas reales. Para ello se utiliza K-Means, un algoritmo de agrupamiento que asigna cada punto al centroide más cercano y recalcula esos centroides hasta estabilizar la partición (Lloyd, 1982). Esta decisión es importante porque separa dos momentos del análisis: primero se agrupa por similitud de expresión; después se revisa si esos grupos coinciden con los tipos tumorales conocidos. Así se evita que las etiquetas guíen el agrupamiento y se conserva el carácter no supervisado del experimento.

Objetivo e hipótesis

El objetivo del proyecto es analizar perfiles de expresión génica RNA-Seq de cáncer mediante PCA y K-Means para evaluar si las muestras se agrupan de acuerdo con su tipo tumoral.

La hipótesis de trabajo es que, si cada tipo de cáncer tiene genes activos de forma distinta, entonces las muestras del mismo tipo deberían parecerse más entre sí que a las de otros tumores al proyectarse con PCA y al agruparse con K-Means. Esta hipótesis no implica que la separación sea perfecta ni que el método tenga valor diagnóstico por sí solo. Su alcance es más acotado: comprobar si un flujo exploratorio reproducible permite observar estructura relacionada con el tipo tumoral.

Datos

El conjunto de datos seleccionado es *Gene Expression Cancer RNA-Seq*, publicado por Fiorini en el UCI Machine Learning Repository bajo licencia CC BY 4.0 (Fiorini, 2016). El recurso corresponde a una extracción aleatoria del conjunto PANCAN RNA-Seq de TCGA, asociado con perfiles de expresión de tumores humanos (The Cancer Genome Atlas Research Network, 2013). La matriz contiene 801 muestras y 20,531 atributos, donde cada atributo representa el nivel de expresión de un gen. Las etiquetas disponibles corresponden a cinco tipos tumorales: carcinoma de mama (BRCA), carcinoma renal de células claras (KIRC), adenocarcinoma de colon (COAD), adenocarcinoma de pulmón (LUAD) y adenocarcinoma de próstata (PRAD) (Fiorini, 2016).

El dataset ya se entrega como matriz de expresión procesada. Esto delimita el alcance del trabajo: no se ejecuta el procesamiento primario de RNA-Seq, como control de calidad de archivos FASTQ, alineamiento de lecturas, cuantificación inicial ni normalización desde datos crudos. El análisis inicia en la tabla numérica final, donde las filas son muestras y las columnas son atributos de expresión. Esa decisión es adecuada para el objetivo del proyecto porque la pregunta no es cómo producir la matriz desde lecturas, sino si la matriz conserva estructura suficiente para separar tipos tumorales mediante un flujo no supervisado.

La forma conceptual de la matriz es muestras por genes. Cada fila representa una muestra tumoral y cada columna representa un gen. El valor numérico de una celda indica el nivel de expresión de ese gen en esa muestra. Esta organización permite tratar cada muestra como un punto en un espacio de expresión génica. Dos muestras cercanas en ese espacio tienen perfiles de expresión más parecidos entre sí, mientras que muestras lejanas muestran diferencias mayores en sus niveles de expresión.

Aunque el dataset incluye etiquetas reales, éstas no se emplean para entrenar un clasificador. Su uso se reserva para describir el conjunto, colorear visualizaciones interpretativas y comparar los grupos generados por K-Means contra las clases conocidas. Esta separación metodológica es necesaria porque el propósito del trabajo no es predecir una etiqueta a partir de ejemplos supervisados, sino observar si la estructura del dato permite recuperar agrupamientos relacionados con los tipos tumorales. Además, los nombres de genes están anonimizados, por lo que

el análisis no busca identificar mecanismos biológicos específicos ni rutas moleculares; se concentra en la estructura global de los perfiles de expresión.

Metodología

El flujo comienza con la carga del dataset y la separación entre la matriz de expresión, representada como X, y las etiquetas tumorales, representadas como y. En esta etapa se revisan las dimensiones del conjunto, la distribución de clases y la presencia de valores faltantes. Esta revisión inicial no resuelve todavía el problema de la alta dimensionalidad, pero permite verificar que la matriz está en condiciones de pasar a las transformaciones posteriores.

El siguiente paso es la estandarización. Como cada gen puede tener una escala numérica distinta, se transforma cada variable para que tenga media cero y desviación estándar uno. Con esto se evita que un gen domine el análisis únicamente por su magnitud numérica. La estandarización es especialmente importante antes de PCA, porque las componentes se calculan a partir de la variación observada en las variables; si las escalas no se equilibran, la reducción puede reflejar diferencias de escala en lugar de estructura biológica.

Después se seleccionan los genes de mayor varianza. Esta decisión reduce el número de atributos antes de aplicar PCA y concentra el análisis en genes que cambian más entre muestras. La selección por varianza no identifica por sí misma genes causalmente importantes, pero ayuda a disminuir ruido y costo computacional en un análisis exploratorio. En la ejecución final se redujeron 5,000 genes, por lo que el análisis redujo la matriz de 20,531 a 5,000 atributos antes de la estandarización y de PCA.

Con la matriz estandarizada y reducida por varianza se aplica PCA. El resultado principal de esta etapa es una nueva matriz donde las muestras se describen por componentes principales. Se registran la varianza explicada por cada componente y la varianza acumulada, porque esos valores indican cuánta información del conjunto original se conserva en la proyección. Para la presentación visual se usa principalmente el plano formado por PC1 y PC2, coloreando primero por tipo tumoral real.

Sobre la representación reducida se aplica K-Means. El valor de k no debe fijarse sólo porque existen cinco etiquetas tumorales, ya que el algoritmo trabaja sin conocer esas etiquetas. En su lugar, se evalúan varios valores de k y se calculan dos métricas internas para cada partición. Davies-Bouldin compara la compacidad interna de los clusters con la separación entre ellos; valores menores indican mejor separación relativa (Davies y Bouldin, 1979). Silhouette compara, para cada muestra, qué tan cerca está de su propio cluster frente a los clusters vecinos; valores mayores indican agrupamientos más coherentes (Rousseeuw, 1987). En esta ejecución, k=5 se conserva como elección principal porque minimiza Davies-Bouldin y coincide con una partición interpretable frente a las clases reales.

Finalmente se compara la asignación de clusters contra las etiquetas reales. Esta comparación puede hacerse mediante una tabla de contingencia y una visualización de PC1 contra PC2 coloreada por cluster. Además se reportan tres métricas externas. La pureza mide qué proporción de muestras queda en clusters dominados por su clase mayoritaria; ARI compara dos particiones corrigiendo parte del acuerdo esperado por azar (Hubert y Arabie, 1985); NMI mide la información compartida entre clusters y etiquetas reales en una escala normalizada (Vinh, Epps y Bailey, 2010). Estas métricas se calculan después de formar los clusters, por lo que funcionan como evaluación posterior y no como entrenamiento.

Resultados

El primer resultado observable fue la distribución de muestras por tipo tumoral. El conjunto no está completamente balanceado: BRCA tiene 300 muestras, KIRC 146, LUAD 141, PRAD 136 y COAD 78. Esta distribución debe

considerarse al interpretar las gráficas, porque BRCA tiene una presencia mayor que el resto de las clases y COAD es la clase con menor número de muestras.

La revisión inicial no identificó valores faltantes en la matriz de expresión. La matriz original tuvo 801 muestras por 20,531 genes, y el flujo retuvo 5,000 genes de mayor varianza antes de aplicar PCA. Esta reducción no transforma el análisis en una búsqueda de biomarcadores; únicamente acota el espacio de entrada para que las componentes principales se calculen sobre genes con variación observable entre muestras.

En PCA, PC1 explicó 15.46% de la variación y PC2 explicó 11.34%. En conjunto, las dos primeras componentes explicaron 26.81% de la variación total. Las diez primeras componentes acumularon 56.02%. Esta lectura es relevante porque el plano PC1-PC2 no resume todo el dataset, pero sí concentra suficiente estructura para observar patrones globales. Por esa razón, la gráfica bidimensional debe usarse como una vista exploratoria y no como una representación completa de la matriz de expresión.

La proyección PC1 contra PC2 coloreada por tipo tumoral mostró separación clara para varios grupos. BRCA se ubicó principalmente hacia una región derecha del plano; KIRC apareció separado hacia la izquierda; PRAD ocupó una zona superior; LUAD y COAD quedaron más cercanos entre sí en la parte inferior del espacio proyectado. Este patrón sugiere que una parte importante de la variación transcriptómica coincide con diferencias entre tipos tumorales, aunque también muestra que no todos los tumores quedan separados con la misma nitidez en dos dimensiones.

Para K-Means se evaluaron valores de k entre 2 y 10 usando Davies-Bouldin y Silhouette. El menor Davies-Bouldin se obtuvo con $k=5$, con un índice de 0.9313. Silhouette fue 0.4555 para $k=5$, mientras que su valor máximo en el rango evaluado fue 0.4652 con $k=6$. Esta diferencia es importante para la interpretación: Silhouette no contradice el resultado, pero muestra que la estructura no debe presentarse como perfecta. En el proyecto se mantiene $k=5$ porque Davies-Bouldin favorece esa partición, porque coincide con una solución de cinco grupos interpretables y porque la comparación posterior con etiquetas reales muestra una correspondencia muy alta.

La comparación final entre clusters y etiquetas reales mostró una correspondencia fuerte. BRCA quedó completamente asignado al cluster 0; PRAD quedó completamente asignado al cluster 3; KIRC quedó casi por completo en el cluster 2, con una muestra en el cluster 1; LUAD quedó principalmente en el cluster 1, con dos muestras en el cluster 0; COAD quedó principalmente en el cluster 4, con cuatro muestras en el cluster 1. La mezcla más visible ocurrió entre COAD y LUAD, que también aparecían cercanos en la proyección PCA.

Las métricas externas refuerzan esa lectura. La pureza fue 0.9913, lo que significa que casi todas las muestras cayeron en clusters dominados por su tipo tumoral correspondiente. El ARI fue 0.9829 y el NMI fue 0.9717; ambos valores están cerca de 1, lo que indica alto acuerdo entre la partición no supervisada y las etiquetas reales. En conjunto, estos resultados apoyan la hipótesis exploratoria: los perfiles RNA-Seq contienen estructura suficiente para recuperar agrupamientos relacionados con el tipo tumoral.

Figuras principales




Figura 1. Distribución de muestras por tipo tumoral.




Figura 2. Proyección PCA de las muestras coloreada por etiqueta real.




Figura 3. Métricas internas para la selección de k: Davies-Bouldin y Silhouette.




Figura 4. Correspondencia entre tipo tumoral real y cluster asignado.

Discusión

El valor principal de este proyecto está en mostrar cómo una pregunta biológica puede formularse como un problema computacional reproducible. La pregunta no es si el algoritmo puede diagnosticar cáncer, sino si la matriz de expresión contiene patrones que separan tipos tumorales cuando se resume su variación y se agrupa por similitud. Esta diferencia de alcance es importante porque evita sobreinterpretar los resultados y mantiene el trabajo dentro de una exploración de datos genómicos.

PCA aporta una primera lectura de la estructura global, pero también impone límites. Al concentrar la variación en componentes principales, favorece las direcciones donde el conjunto cambia más. Esas direcciones pueden coincidir con diferencias entre tipos tumorales, pero también pueden reflejar otros factores, como heterogeneidad interna, variación técnica o diferencias de procesamiento. Por ello, una separación visual en PC1 y PC2 debe leerse como una señal exploratoria y no como prueba definitiva de identidad molecular.

K-Means introduce otro límite metodológico. El algoritmo busca clusters compactos alrededor de centroides y funciona mejor cuando los grupos tienen formas aproximadamente esféricas y tamaños comparables. Los perfiles tumorales, sin embargo, pueden tener estructuras más complejas. Además, el número de clusters elegido por Davies-Bouldin optimiza una medida geométrica interna, no una correspondencia biológica. Por esa razón, Davies-Bouldin y Silhouette ayudan a revisar la calidad geométrica de la partición, pero no sustituyen la comparación posterior con las etiquetas reales.

La evaluación externa también debe leerse con cuidado. Pureza, ARI y NMI se calculan usando las etiquetas reales, pero esas etiquetas no participaron en PCA ni en K-Means. Por tanto, estos valores no significan que se entrenó un clasificador ni que el flujo pueda diagnosticar una muestra nueva. Significan que, en este dataset, los clusters encontrados sin etiquetas coinciden fuertemente con los tipos tumorales ya conocidos.

Una limitación adicional está en los nombres de las variables. El dataset usa identificadores anonimizados para los genes, de modo que los loadings de PCA no pueden traducirse directamente a rutas biológicas o mecanismos celulares. Es posible saber qué variables contribuyen más a PC1 o PC2 en sentido matemático, pero no interpretar esas variables como genes reales con una función conocida. Por eso la conclusión biológica debe formularse a nivel global: hay señal transcriptómica suficiente para separar tipos tumorales, no identificación de mecanismos biológicos específicos.

Aun con esas restricciones, el flujo tiene utilidad educativa y analítica. Permite revisar una matriz transcriptómica de alta dimensionalidad, aplicar transformaciones estándar, producir figuras interpretables y discutir la relación entre estructura computacional y significado biológico. Si los grupos se alinean con los tipos tumorales, el resultado apoyará la hipótesis de que los perfiles RNA-Seq conservan señales suficientes para separar ciertos tumores. Si la alineación es parcial, el trabajo seguirá siendo útil porque permitirá identificar dónde el método se queda corto y qué análisis serían necesarios para profundizar.

Conclusiones

Este proyecto plantea un análisis exploratorio de expresión génica en cáncer usando una secuencia de pasos reproducible: revisión de datos, estandarización, selección de genes por varianza, reducción de dimensión con PCA, agrupamiento con K-Means y comparación final con etiquetas reales. La estructura del flujo permite separar el descubrimiento no supervisado de la interpretación biológica posterior.

El dataset seleccionado es adecuado para esta pregunta porque combina una cantidad moderada de muestras con una cantidad alta de genes, lo que obliga a tratar explícitamente el problema de la alta dimensionalidad. Además, las cinco clases tumorales disponibles ofrecen una referencia para interpretar si los agrupamientos encontrados tienen relación con tipos de cáncer conocidos.

Los resultados sostienen la hipótesis de manera clara pero acotada. La separación observada en PCA, el valor de $k=5$ sugerido por Davies-Bouldin, el Silhouette de 0.4555 para esa partición, la matriz de contingencia y las métricas externas indican que los perfiles RNA-Seq conservan señal suficiente para separar la mayoría de los tipos tumorales en este conjunto. La conclusión debe mantenerse como exploratoria: el flujo no valida un modelo diagnóstico, no identifica genes causales y no sustituye análisis biológicos más específicos. Su aportación principal es mostrar, con código reproducible, cómo una matriz transcriptómica de alta dimensionalidad puede analizarse mediante reducción de dimensión, agrupamiento no supervisado e interpretación posterior contra etiquetas conocidas.

Bibliografía

- Davies, D. L. y Bouldin, D. W. (1979). A cluster separation measure. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, PAMI-1(2), 224-227. <https://doi.org/10.1109/TPAMI.1979.4766909>
- Fiorini, S. (2016). *Gene Expression Cancer RNA-Seq* [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5R88H>
- Hubert, L. y Arabie, P. (1985). Comparing partitions. *Journal of Classification*, 2, 193-218. <https://doi.org/10.1007/BF01908075>
- Jolliffe, I. T. y Cadima, J. (2016). Principal component analysis: a review and recent developments. *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences*, 374(2065), 20150202. <https://doi.org/10.1098/rsta.2015.0202>
- Lloyd, S. P. (1982). Least squares quantization in PCM. *IEEE Transactions on Information Theory*, 28(2), 129-137. <https://doi.org/10.1109/TIT.1982.1056489>
- Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53-65. [https://doi.org/10.1016/0377-0427\(87\)90125-7](https://doi.org/10.1016/0377-0427(87)90125-7)
- The Cancer Genome Atlas Research Network. (2013). The Cancer Genome Atlas Pan-Cancer analysis project. *Nature Genetics*, 45, 1113-1120. <https://doi.org/10.1038/ng.2764>
- Vinh, N. X., Epps, J. y Bailey, J. (2010). Information theoretic measures for clusterings comparison: Variants, properties, normalization and correction for chance. *Journal of Machine Learning Research*, 11, 2837-2854. <https://jmlr.org/papers/v11/vinh10a.html>
- Wang, Z., Gerstein, M. y Snyder, M. (2009). RNA-Seq: a revolutionary tool for transcriptomics. *Nature Reviews Genetics*, 10(1), 57-63. <https://doi.org/10.1038/nrg2484>